Introduction — EV 消费者转化分析初赛提交说明

① 设计思路

本作品针对问卷型表格数据上的三个分类任务，统一采用「冻结划分 + 折内预处理 + OOF 选型 + 最终验证」流程，避免信息泄漏。

- 任务一（EV 采用意愿，Low/Medium/High）：标签有序。保留 CatBoost 多分类主模型（M1），并引入有序回归软概率（M3）与双阈值 Logistic（M6）作为异构概率源，按验证网格搜索得到 soft_vote 权重（M6:0.55, M1:0.35, M3:0.10）。该融合兼顾可解释线性序数结构与非线性交互，在 Medium 类上更稳健。
- 任务二（续航焦虑二分类）：系统性可分性/置换检验/多 seed 冲高后，可部署 Acc 增益门控未通过，按 0-1 损失 Bayes 决策锁定多数类常数分类器。这不是“不做模型”，而是用证据拒绝虚假提升。
- 任务三（支付意愿二分类）：在机制特征（concern 比率/缺口）增强特征集上，以 CatBoost 分类（M1）为主、回归分支（M2）为辅做 soft 融合，阈值 0.5。

可行性：全部依赖公开表特征与可复现脚本；与赛题契合在于尊重标签结构（有序/弱信号/阈值二分类），而非盲目堆叠复杂模型。

② 环境 & 语言

项 | 说明
系统 | Windows 10 / 亦可 Linux
语言 | Python 3.12（推荐 `.venv-shap`）
核心依赖 | pandas, numpy, scikit-learn, catboost, joblib；可解释性另需 shap, matplotlib
数据 | `dataSetB.csv`（选手自备，不随本包分发时请向数据管理员索取）
随机种子 | 42（见各任务 `*_final_config.json`）
划分 | develop 80% / final_validation 20%，分层抽样，索引冻结于 `outputs/*/splits/`

安装示例：

```
python -m venv .venv
.venv\Scripts\activate
pip install -r requirements.txt
# 或: uv pip install --python .venv-shap\Scripts\python.exe -r requirements.txt
```

③ 模型调用方式

各任务模型目录见 任务*/02_训练好的模型/，推理脚本见 任务*/01_源代码/infer_task*.py。

任务一 soft_vote

1. 读取 task1_model_bundle.json 获取特征列表与权重。
2. 加载：
- task1_m1_catboost.cbm + task1_cat_prep_state.joblib
- task1_m3_regressor.cbm（温度 m3_temperature，默认 0.5）
- task1_m6_ord_logit.joblib（含两个 Logistic 与表格预处理）
3. 对每个样本得到三类概率 p_M1, p_M3, p_M6，按权重加权归一后 argmax → {Low,Medium,High}。

```
python 任务一_EV采用意愿/01_源代码/infer_task1.py --data dataSetB.csv --model_dir 任务一_EV采用意愿/02_训练好的模型 --out pred1.csv
```

任务二 majority

读取 task2_majority_model.json 中 majority_class（通常为 1），对所有行输出该常数。

```
python 任务二_续航焦虑二分类/01_源代码/infer_task2.py --data dataSetB.csv --model_dir 任务二_续航焦虑二分类/02_训练好的模型 --out pred2.csv
```

任务三 soft fusion

1. 加载 task3_m1_catboost.cbm 与 prep state → p1 = P(y=1)。
2. 加载 task3_m2_regressor.cbm：将连续分映射为概率（或按源码与 M1/M4 权重融合；提交包默认权重 M1:0.8, M2:0.15, M4:0.05，部署可简化为 M1+M2）。
3. pred = 1 if p_soft >= threshold(0.5) else 0。

```
python 任务三_支付意愿二分类/01_源代码/infer_task3.py --data dataSetB.csv --model_dir 任务三_支付意愿二分类/02_训练好的模型 --out pred3.csv
```

输出格式建议

推理输出 CSV 至少包含：样本行号, 预测类标签；若有真值可附 真值类标签 便于自测。